




Twitch Gamers Social Network

Proyecto Final: Datos Masivos

Abril Minerva Estrada Montaña

Erick José Fabián Sandoval

Contenido



- **Análisis y Construcción del Grafo**
- **Identificación de Comunidades**
- **Predicción del Idioma**
- **Predicción de la popularidad**

Introducción y Objetivos del Proyecto

Un análisis exhaustivo del grafo de usuarios de Twitch utilizando ciencia de redes, machine learning y métodos estadísticos. Los objetivos principales incluyen:

Análisis Estructural

Comprender la estructura global, la distribución de grados y determinar si sigue una Ley de Potencia (Red Libre de Escala).

Detección de Comunidades

Detectar comunidades estructurales usando Louvain y caracterizarlas por atributos de usuario como idioma y estado de afiliado.

Influencia y Centralidad

Medir la influencia de usuarios usando métricas de centralidad de Grado, PageRank y Eigenvector para identificar "Superhubs".

Machine Learning

Predecir el **Idioma** (Clasificación) y la **Popularidad/Vistas** (Regresión) usando embeddings de nodos y atributos.


Fuente de los Datos

Una red social de usuarios de Twitch que fue recolectada a partir de la API pública en la primavera de 2018. Los nodos representan usuarios de Twitch y las aristas corresponden a relaciones de seguimiento mutuo entre ellos. El grafo forma un solo componente fuertemente conectado y no presenta atributos faltantes.

Disponibles en: https://snap.stanford.edu/data/twitch_gamers.html

Paper: <https://arxiv.org/pdf/2101.03091>

Github: <https://github.com/benedekrozemberczki/datasets>



Resumen del Dataset

Características Extraídas (Features):

Idioma

Vistas Totales

Estado de Afiliado

Contenido Maduro

Tiempo de vida de cuenta

168,114

NODOS TOTALES
(USUARIOS)

6.8M

ARISTAS TOTALES
(FOLLOWS)

Se obtienen:

- **Promedio de grado:** ~80
- **Mediana:** 32
- **Máximo:** más de 35,000
- **Un solo componente gigante:** 168,114 nodos
- **Clustering global:** 0.1599


Construcción del Grafo

Grafo No Dirigido $G(V, E)$


Se construyó un grafo no dirigido donde:

- **Nodos (V):** Representan usuarios individuales de Twitch (streamers/viewers).
- **Aristas (E):** Representan relaciones de seguimiento mutuo.

El grafo forma una red social masiva y altamente conectada sin atributos faltantes. Esta densidad permite un análisis topológico robusto.




Análisis Estructural: Distribución de Grados



Distribución de Cola Larga


Twitch se comporta como una red social típica con una distribución de grados altamente sesgada. La mayoría tiene pocas conexiones, mientras que unos pocos "Hubs" tienen miles.

Detección de Ley de Potencia



Un exponente entre 2 y 3 confirma que Twitch es una **Red Libre de Escala**, caracterizada por robustez ante fallos aleatorios pero vulnerabilidad a ataques dirigidos a hubs.

Ajuste de ley de potencia (método Clauset-Shalizi-Newman)



Centralidad e Influencia

Construimos una métrica de centralidad para cada nodo a través de estas tres:

Grado (Degree)

Popularidad. Simplemente el número de seguidores. Los nodos de alto grado son visibles pero no siempre los más influyentes en el flujo de información.

PageRank

Influencia. Mide la *calidad* de las conexiones. Un usuario seguido por otros streamers famosos tiene mayor PageRank. Correlaciona al 99% con Grado.

Eigenvector

Liderazgo. Identifica líderes dentro de subcomunidades específicas. Útil para encontrar figuras clave en clusters de idiomas aislados.

PageRank

```
[ (61862, 0.006501592216014649),  
  (71050, 0.004998370573404596),  
  (125642, 0.004004273305136171),  
  (32338, 0.0034273271834444306),  
  (110345, 0.002445423998280764),  
  (64605, 0.0023517630146510184),  
  (155127, 0.0020242497968631866),  
  (6250, 0.0018547197778304885),  
  (128864, 0.0017837545127664285),  
  (139587, 0.0017386030921850756) ]
```

Correlación de nuestras variables

Insight: El número total de vistas fue el que representó mayores correlaciones con las métricas que extrajimos.

	degree centrality	pagerank	eigenvector	views
degree centrality	1.000000	0.994049	0.874097	0.836135
pagerank	0.994049	1.000000	0.840986	0.833978
eigenvector	0.874097	0.840986	1.000000	0.674527
views	0.836135	0.833978	0.674527	1.000000

Detección de Comunidades (Louvain)

Usando el algoritmo Louvain, identificamos grupos modulares distintos dentro de la red. Para visualizar este grafo masivo, empleamos **Muestreo Estratificado** combinado con la preservación de Superhubs.

El algoritmo busca maximizar una medida llamada modularidad, que evalúa qué tan buenas son las particiones de la red en comunidades.

23

COMUNIDADES DETECTADAS

Subgrafo representativo de Twitch (muestral + comunidades + hubs)



Embeddings y Visualización UMAP

Node2Vec + UMAP

Generamos embeddings estructurales de 64 dimensiones para cada usuario usando **Node2Vec** y los proyectamos en 2D usando **UMAP**.

- **Mezcla Central:** El núcleo contiene muchas comunidades superpuestas, probablemente de habla inglesa y hubs altamente interconectados.
- **Clusters Periféricos:** Islas distintas y separadas que suelen corresponder a idiomas específicos (Ruso, Turco, Francés) o nichos temáticos.

Embeddings Node2Vec proyectados con UMAP (coloreado por comunidad)



Interpretación de Comunidades


El idioma fue el predictor más fuerte de la estructura comunitaria. La "Homofilia" (los iguales se agrupan con iguales) es evidente.

community	size	top_languages	affiliate_rate	mature_rate	avg_views	median_views	avg_life_days
4	123	{'EN': 112, 'FR': 3, 'SV': 2}	0.439024	0.414634	2.036668e+06	6358.0	1977.813008
12	121	{'DE': 114, 'EN': 6, 'ES': 1}	0.471074	0.545455	5.693659e+05	4995.0	1323.677686
10	120	{'TH': 72, 'EN': 41, 'OTHER': 7}	0.408333	0.233333	5.500893e+05	5218.0	875.833333
9	120	{'RU': 115, 'EN': 5}	0.491667	0.258333	1.048138e+05	8835.0	1365.475000
11	120	{'IT': 118, 'ZH': 1, 'EN': 1}	0.600000	0.208333	1.352968e+05	5894.0	1302.183333
15	120	{'TR': 79, 'HU': 34, 'EN': 6}	0.566667	0.341667	8.369992e+05	10554.0	1203.908333
17	120	{'FI': 107, 'EN': 13}	0.533333	0.500000	1.511664e+05	10396.0	1697.625000
14	120	{'FR': 118, 'OTHER': 1, 'TR': 1}	0.516667	0.350000	7.328776e+04	6367.5	1401.433333
13	120	{'PT': 119, 'FR': 1}	0.541667	0.375000	3.179125e+05	10751.5	1314.916667
6	120	{'ZH': 70, 'KO': 26, 'JA': 17}	0.308333	0.291667	3.249290e+05	14270.0	1690.150000

Nota: Las comunidades en inglés suelen ser más grandes pero menos distintivas estructuralmente, fusionándose en el núcleo global.

Relaciones entre superhubs

Superhubs en el grafo de Twitch (grado más alto)




Tarea ML 1: Predicción de Idioma

Modelos de Clasificación

Objetivo: Predecir el idioma de un streamer basado en sus conexiones de red (embeddings) y métricas de centralidad.

Features: Embeddings Node2Vec, Centralidades como PageRank, Grado, Estado de Afiliado.



Tarea ML 2: Predicción de Popularidad


Análisis de Regresión

Objetivo: Predecir vistas totales (\$y\$).

Reto: Las vistas siguen una ley de potencia masiva (rango: 2 a 300M+). Aplicamos transformación logarítmica: $y = \log(1+x)$


Mejor Modelo: XGBoost.

```
RMSE: 3862020.7022543135  
MAE: 701048.9280560222  
R2 : 0.6359012667413384
```



Factores de Popularidad

¿Qué determina cuántas vistas obtiene un streamer? El análisis de importancia de características de XGBoost reveló que la estructura de la red es la más importante




Conclusiones

- El grafo de Twitch es altamente conectado, con distribución de grado de cola pesada y presencia clara de superhubs, típico de redes sociales reales.
- La red presenta comunidades bien definidas, principalmente organizadas por idioma, confirmadas por Louvain y por los embeddings Node2Vec + UMAP.
- Las medidas de centralidad identifican un núcleo de usuarios influyentes que estructuran gran parte del flujo en la red.



Conclusiones



- Los modelos de ML muestran que la estructura del grafo permite predecir idioma con buen desempeño (LogReg y Random Forest).
- Para popularidad, XGBoost explica ~64% de la variabilidad, mostrando que las propiedades de la red sí contienen información predictiva sobre el éxito de los usuarios.

Gracias

¿Preguntas?

Referencias:

- Barabási, A.-L. (2016). *Network Science*.
- Clauset, A., et al. (2009). *Power-Law Distributions in Empirical Data*.
- Grover, A., & Leskovec, J. (2016). *node2vec: Scalable Feature Learning*.