

Análisis de la Red Social de Twitch: Estructura, Comunidades y Predicción de Popularidad

Abril Minerva Estrada Montaña

Erick José Fabián Sandoval

1 de diciembre de 2025

Resumen

Este informe presenta un análisis exhaustivo del grafo de usuarios de Twitch, una de las plataformas de transmisión en vivo más grandes del mundo. Utilizando datos de más de 168,000 usuarios y casi 1 millón de relaciones de seguimiento, aplicamos técnicas modernas de ciencia de redes, aprendizaje automático y estadística avanzada. Nuestro análisis confirma que la red sigue una distribución de ley de potencia con exponente $\alpha \approx 2,54$, indicando una estructura scale-free caracterizada por pocos superhubs altamente conectados. Detectamos 23 comunidades estructurales mediante el algoritmo de Louvain, frecuentemente organizadas por idioma y preferencias temáticas. Los modelos de predicción alcanzaron precisión del 86 % en clasificación de idioma y un coeficiente de determinación $R^2 = 0,64$ en estimación de popularidad. Estos resultados demuestran que la posición estructural en la red es un predictor fundamental de influencia y visibilidad en plataformas digitales.

Índice

1. Introducción y Antecedentes	4
1.1. Contexto General	4
1.2. Motivación del Proyecto	4
1.3. Objetivos del Análisis	4
2. Metodología	5
2.1. Fuente de Datos	5
2.2. Construcción del Grafo	5
2.3. Análisis Estadístico Descriptivo	5
2.4. Detección de Ley de Potencia	6
2.5. Detección de Comunidades	6
2.6. Embeddings Estructurales: Node2Vec	7
2.7. Visualización: UMAP	7
2.8. Cálculo de Centralidades	7
2.9. Tareas de Predicción Supervisada	7
2.9.1. Tarea 1: Predicción de Idioma	7
2.9.2. Tarea 2: Predicción de Popularidad	8
2.10. Protocolo de Evaluación	8
3. Resultados y Discusión	8
3.1. Caracterización Estructural del Grafo	8
3.2. Validación de Ley de Potencia	9
3.3. Estructura de Comunidades	9
3.3.1. Dominancia Lingüística	9
3.3.2. Comunidades Angloparlantes Mezcladas	10
3.3.3. Heterogeneidad en Popularidad	10
3.4. Análisis de Centralidades	10
3.5. Predicción de Idioma	10
3.5.1. Rendimiento de Modelos	10
3.5.2. Interpretación	11
3.6. Predicción de Popularidad (Views)	11
3.6.1. Estrategia de Modelado	11
3.6.2. Rendimiento	11
3.6.3. Feature Importance	12
3.6.4. Interpretación e Implicaciones	12
3.7. Validación Cruzada y Robustez	13

4. Conclusiones	13
4.1. Hallazgos Principales	13
4.2. Implicaciones Prácticas	13
4.3. Limitaciones y Trabajo Futuro	14
4.4. Reflexión Final	14

1. Introducción y Antecedentes

1.1. Contexto General

Twitch es una plataforma de transmisión en vivo que se ha convertido en un ecosistema digital masivo, con millones de usuarios conectados diariamente. La estructura de seguimiento entre usuarios forma una red compleja que refleja patrones de influencia, afinidad y comunidad. Comprender esta red es fundamental para analizar fenómenos como la viralidad de contenidos, la formación de comunidades temáticas, y la distribución de oportunidades de monetización.

El análisis de redes sociales ha demostrado ser una herramienta poderosa para revelar patrones ocultos en sistemas complejos. En particular, redes reales como Twitch frecuentemente muestran características no triviales: distribuciones heterogéneas de conectividad, modularidad comunitaria, y la presencia de nodos influyentes que actúan como puentes globales.

1.2. Motivación del Proyecto

Este proyecto surge de la pregunta fundamental: *¿Qué determina la influencia y popularidad de un streamer en Twitch?* Hipotetizamos que la respuesta no reside únicamente en características individuales del canal, sino en la posición estructural que ocupa dentro de la red de usuarios. Para validar esta hipótesis, realizamos un análisis integrado que combina:

- Caracterización estructural del grafo (grados, componentes, clustering)
- Identificación de leyes de potencia mediante métodos robustos
- Detección y caracterización de comunidades
- Cálculo de centralidades de red
- Generación de embeddings estructurales
- Predicción supervisada de atributos y métricas

1.3. Objetivos del Análisis

Los objetivos específicos fueron:

1. Caracterizar la estructura global del grafo de Twitch (tamaño, densidad, conectividad)
2. Validar si la distribución de grados sigue una ley de potencia genuina

3. Detectar comunidades modulares y caracterizarlas por atributos de usuario
4. Obtener representaciones latentes mediante Node2Vec y UMAP
5. Medir la influencia de usuarios mediante múltiples centralidades
6. Predecir el idioma de streamers a partir de características estructurales
7. Estimar la popularidad (views) basándose en posición en la red

2. Metodología

2.1. Fuente de Datos

Los datos provienen del dataset público de Twitch disponible en el Stanford Large Network Dataset Collection (`snap.stanford.edu`), recolectados en primavera de 2018 mediante la API pública de Twitch. El dataset contiene:

- **Archivo de aristas:** Relaciones de seguimiento mutuo entre usuarios
- **Archivo de atributos:** Características por usuario incluyendo idioma, vistas totales, estado de afiliado, actividad, y timestamps de creación

El grafo resultante es no dirigido, conectado, y sin atributos faltantes para los nodos incluidos en el análisis principal.

2.2. Construcción del Grafo

Se construyó un grafo no dirigido $G = (V, E)$ donde:

- V : conjunto de 168,114 nodos (usuarios de Twitch)
- E : conjunto de aproximadamente 1,000,000 de aristas (relaciones de seguimiento)

El grafo forma un único componente gigante, indicando alta interconectividad y que la mayoría de usuarios están conectados transitivamente.

2.3. Análisis Estadístico Descriptivo

Se calcularon estadísticas fundamentales:

- **Grado promedio:** $\langle k \rangle \approx 80$
- **Mediana de grado:** $\tilde{k} \approx 32$
- **Grado máximo:** $k_{\text{máx}} > 35,000$

- **Coeficiente de clustering global:** $C \approx 0,1599$
- **Componentes conectados:** 1 (grafo conectado)

La gran disparidad entre media y mediana del grado, junto al alto grado máximo, sugiere una distribución altamente sesgada característica de redes scale-free.

2.4. Detección de Ley de Potencia

Se empleó el método estadístico de Clauset–Shalizi–Newman (2009), considerado el estándar de oro para validar distribuciones de ley de potencia. El método:

1. Propone que la cola de la distribución sigue $P(k) \propto k^{-\alpha}$ para $k \geq k_{\min}$
2. Optimiza $k_{\min}$ minimizando la distancia de Kolmogorov–Smirnov entre CDF empírica y teórica
3. Estima el exponente α mediante máxima verosimilitud

Resultados obtenidos:

- $k_{\min} = 250$ (umbral óptimo de la cola)
- $\alpha = 2,54$ (exponente de ley de potencia)
- Tamaño de cola: 9,141 nodos
- Distancia KS mínima: 0.0048 (excelente ajuste)

El exponente $\alpha \in [2, 3)$ es característico de redes scale-free, implicando presencia de superhubs, sensibilidad a ataques dirigidos, y robustez ante fallos aleatorios.

2.5. Detección de Comunidades

Se aplicó el algoritmo de Louvain para detección de comunidades modulares. Este algoritmo:

- Optimiza la modularidad del grafo de manera greedy
- Es escalable a redes masivas
- Produce una partición jerárquica de nodos

Se detectaron 23 comunidades, que se caracterizaron mediante variables agregadas: idioma dominante, tasa de afiliación, tasa de contenido adulto, vistas promedio/mediana, y antigüedad media.

2.6. Embeddings Estructurales: Node2Vec

Para obtener representaciones latentes de nodos, se entrenó Node2Vec:

- Dimensionalidad: 64
- Paseos aleatorios por nodo: 150
- Longitud de paseo: 20
- Ventana de contexto: 10

Estos embeddings capturan la proximidad estructural en la red, permitiendo análisis de similitud y visualización.

2.7. Visualización: UMAP

Se proyectaron los embeddings de 64 dimensiones a 2D mediante UMAP (Uniform Manifold Approximation and Projection), preservando la estructura local y revelando clusters de nodos similares.

2.8. Cálculo de Centralidades

Se computaron cuatro medidas de centralidad para cada nodo:

1. **Degree Centrality:** $C_d(i) = \frac{k_i}{n-1}$
2. **PageRank:** Importancia ponderada según prestigio de vecinos
3. **Eigenvector Centrality:** Conectividad a otros nodos influyentes
4. **Betweenness Centrality (aproximada):** Frecuencia como puente en caminos cortos

2.9. Tareas de Predicción Supervisada

2.9.1. Tarea 1: Predicción de Idioma

Se formuló como clasificación multinomial con 18 clases (idiomas únicos tras colapsar raros). Variables predictoras:

- Centralidades (degree, PageRank, eigenvector, betweenness)
- Atributos del usuario (affiliate, dead_account, vistas, antigüedad)
- Embeddings Node2Vec (64 dimensiones)

Se entrenaron tres modelos:

1. Regresión Logística Multinomial (baseline lineal)
2. Random Forest Classifier (ensemble no lineal)
3. XGBoost Classifier (gradient boosting)

2.9.2. Tarea 2: Predicción de Popularidad

Se formuló como regresión en escala logarítmica. Dado que las vistas siguen una distribución heavy-tailed, se aplicó:

$$y = \log(1 + \text{views})$$

Esto estabiliza la varianza y evita el dominio de outliers. Se entrenaron dos modelos:

1. Random Forest Regressor
2. XGBoost Regressor (modelo final)

Variables predictoras: idénticas a la tarea 1.

2.10. Protocolo de Evaluación

- **Split:** 75 % entrenamiento, 25 % prueba (estratificado para clasificación)
- **Normalización:** StandardScaler para modelos lineales; no necesario para árboles
- **Métricas de clasificación:** Accuracy, precision, recall, F1-score
- **Métricas de regresión:** MAE, RMSE, R^2

3. Resultados y Discusión

3.1. Caracterización Estructural del Grafo

El análisis reveló que Twitch es una red altamente interconectada con características pronunciadas de scale-free network:

- **Conectividad heterogénea:** La distribución de grados es extremadamente sesgada, con el 99 % de usuarios teniendo menos de 2,000 conexiones, mientras que los top 10 superhubs superan las 10,000 cada uno.

- **Clustering moderado:** El coeficiente de clustering global de 0.1599 indica que aproximadamente 16 % de los posibles triángulos en la red existen, sugiriendo que aunque hay clusters locales, la red no es exageradamente aglomerada.
- **Efectos de scale-free:** La presencia de superhubs altamente conectados es característica de redes que exhiben “preferential attachment” — nuevo nodos tienden a conectarse con nodos ya influyentes, amplificando su influencia.

3.2. Validación de Ley de Potencia

El método de Clauset–Shalizi–Newman proporcionó evidencia rigurosa de que la cola de la distribución de grados sigue genuinamente una ley de potencia:

- El exponente $\alpha = 2,54$ es típico de redes de sistemas complejos reales (redes biológicas, sociales, tecnológicas)
- La distancia KS mínima de 0.0048 es extremadamente pequeña, indicando ajuste excelente entre la distribución teórica y empírica
- Implicaciones: La red es robusta ante fallos aleatorios (eliminar usuarios al azar afecta poco), pero vulnerable ante ataques dirigidos a superhubs

3.3. Estructura de Comunidades

El análisis de comunidades reveló patrones claros:

3.3.1. Dominancia Lingüística

La variable más predictiva de pertenencia comunitaria es el idioma. Se observó:

- Comunidades monolingües o con altísima dominancia (¿90 % en un idioma) para idiomas como ruso, turco, polaco, coreano y portugués
- Estas comunidades forman clusters compactos en el espacio de embeddings, indicando homofilia lingüística — usuarios se conectan preferentemente con hablantes de su mismo idioma
- Efecto de audiencias regionales: plataformas de streaming locales con contenido en idiomas específicos atraen comunidades coherentes

3.3.2. Comunidades Angloparlantes Mezcladas

Las comunidades dominadas por inglés muestran un patrón diferente:

- Tamaño más grande (150–300 nodos en promedio)
- Altísima conectividad inter-comunitaria
- Gran dispersión en características (vistas, afiliación)
- Explicación: El inglés es la lingua franca de Twitch, permitiendo conexiones transculturales que no existen en comunidades monolingües

3.3.3. Heterogeneidad en Popularidad

- Algunas comunidades presentan vistas medianas bajas pero un pequeño número de superhubs virales
- Otras muestran homogeneidad: streamers de perfil muy similar con vistas similares
- Las comunidades con mayor popularidad promedio corresponden a idiomas con audiencias muy grandes (español, portugués) o con presencia de influencers globales

3.4. Análisis de Centralidades

Se encontró correlación extremadamente alta ($r > 0,99$) entre degree centrality y PageRank, validando la estructura scale-free (en redes scale-free, el grado es el mejor predictor de importancia).

Hallazgos clave:

- **Superhubs:** Los 15 nodos con mayor grado forman un “núcleo denso” altamente interconectado, actúan como columna vertebral de la red
- **Influencia vs. Grado:** PageRank matiza el grado — algunos usuarios con grado moderado pero conectados a otros influyentes poseen alto PageRank
- **Eigenvector Centrality:** Identifica líderes intra-comunitarios, aquellos altamente conectados dentro de sus clusters temáticos

3.5. Predicción de Idioma

3.5.1. Rendimiento de Modelos

Los resultados de clasificación fueron alentadores:

Modelo	Accuracy	Precisión Promedio	Recall Promedio
Regresión Logística	80.14 %	0.798	0.801
Random Forest	86.46 %	0.864	0.865
XGBoost	87.12 %	0.871	0.870

Cuadro 1: Rendimiento de modelos de clasificación de idioma

3.5.2. Interpretación

- El Random Forest alcanzó 86.46 % de exactitud, capturando bien las jerarquías y no-linealidades en los datos
- XGBoost mejoró ligeramente al 87.12 %, aprovechando mejor la escasez de variables (muchos embeddings capturan info redundante)
- La regresión logística en línea base alcanzó 80.14 %, mostrando que aunque existen separaciones simples entre idiomas (p. ej., clusters monolingües), la mayoría de la predicción requiere modelos no lineales
- **Interpretación:** La estructura de red es tan discriminativa del idioma que modelos complejos extraen patrones sofisticados. Por ejemplo, el idioma correlaciona con PageRank (superhubs tienden a ser de ciertos idiomas) y con embeddings (comunidades forman clusters diferenciados)

3.6. Predicción de Popularidad (Views)

3.6.1. Estrategia de Modelado

Dado que los views siguen una distribución con cola muy pesada (rango: 2 a 300+ millones), se aplicó transformación logarítmica:

$$y = \log(1 + \text{views})$$

Se clipearon valores extremos (máximo 50 millones) para evitar que outliers dominen el entrenamiento.

3.6.2. Rendimiento

El modelo XGBoost final alcanzó:

- $R^2 = 0,64$: El modelo explica el 64 % de la variabilidad en logs-views
- **MAE** $\approx 1,2$ (en escala logarítmica): Error absoluto medio de 1.2 en log-views

- **RMSE** $\approx 1,8$ (en escala logarítmica)

En escala original de views, el $R^2 = 0,64$ es muy respetable considerando la extrema dispersión de los datos.

3.6.3. Feature Importance

El ranking de importancia de características reveló:

1. **PageRank:** Variable dominante por mucho (35 % de importancia relativa)
2. **Language Label:** 18 %
3. **Dead Account:** 12 %
4. **Affiliate:** 8 %
5. **Embeddings Node2Vec:** Distribuido (varias dimensiones con 2–5 % cada una)
6. **Eigenvector Centrality:** 6 %
7. **Degree Centrality:** 4 %

3.6.4. Interpretación e Implicaciones

- **PageRank como predictor dominante:** La posición estructural del canal en la red es el factor más importante para su popularidad. Esto valida nuestra hipótesis inicial: la influencia estructural determina la exposición y alcance
- **Idioma como factor secundario:** El segundo predictor más importante es el idioma, reflejando que audiencias regionales y mercados lingüísticos fragmentan Twitch
- **Estado del canal (dead account):** Canales muertos (sin actividad reciente) tienen systematically lower views, como es esperado. El modelo captura este efecto.
- **Utilidad de embeddings:** Los 64 embeddings de Node2Vec no capturan más información que PageRank solo, pero en conjunto contribuyen valor incremental, sugiriendo que codifican aspectos complementarios (comunidad local, temática, patrones de paseo aleatorio)
- **Limitaciones del modelo:** El $R^2 = 0,64$ indica que 36 % de la variabilidad no se explica. Fuentes de error probable:
 - Contenido y calidad del streamer (no disponible en datos)
 - Actividad temporal (dataset estático, mientras que Twitch es dinámico)
 - Cambios en audiencia post-recolección (datos de 2018)

3.7. Validación Cruzada y Robustez

- Todos los modelos se entrenaron con partición 75/25 stratificada
- No se observó overfitting significativo: las diferencias entre train/test metrics eran menores al 5 %
- La repetibilidad se aseguró mediante semillas aleatorias

4. Conclusiones

Este proyecto integró teoría de redes complejas, estadística avanzada, aprendizaje automático y análisis exploratorio para caracterizar la red social de Twitch de manera rigurosa y multidimensional.

4.1. Hallazgos Principales

1. **Estructura Scale-Free Confirmada:** El análisis mediante Clauset–Shalizi–Newman validó que Twitch es una red scale-free con exponente $\alpha = 2,54$, implicando superhubs influyentes, robustez a fallos aleatorios, y vulnerabilidad a ataques dirigidos.
2. **Modularidad Lingüística:** Las 23 comunidades detectadas se organizan primordialmente por idioma, revelando que la estructura de Twitch refleja geografía e identidad lingüística. Usuarios se conectan preferencialmente con hablantes de su idioma (homofilia).
3. **Influencia Estructural:** PageRank es el predictor más fuerte de popularidad (35 % de importancia), demostrando que la posición en la red determina exposición y alcance, más allá de características individuales del canal.
4. **Precisión Predictiva:** Modelos de aprendizaje automático alcanzaron 87 % de accuracy en clasificación de idioma y $R^2 = 0,64$ en regresión de views, mostrando que características estructurales y latentes capturan información significativa sobre usuarios.
5. **Superhubs como Columna Vertebral:** Los 15 nodos con mayor grado forman un núcleo denso que actúa como la columna vertebral de conectividad global, con acceso privilegiado a diversos públicos.

4.2. Implicaciones Prácticas

- **Para Streamers:** La posición en la red (representada por PageRank, seguidores de calidad, conexiones con influencers) es crucial para alcance. Buscar colaboraciones

estratégicas con nodos bien posicionados puede ampliar audiencia exponencialmente.

- **Para Plataforma:** Twitch podría utilizar posición en red como métrica complementaria para recomendaciones, en lugar de confiar únicamente en vistas o seguidores instantáneos. Esto podría mejorar diversidad en recomendaciones.
- **Para Investigadores:** La metodología integrada aquí (estadística robusta + machine learning) es replicable a otras redes sociales, revelando patrones generales de cómo influencia estructura comunidades digitales.

4.3. Limitaciones y Trabajo Futuro

Limitaciones:

- Datos estáticos de 2018: La red ha evolucionado significativamente
- Falta de información sobre contenido: Temáticas, géneros, calidad
- Falta de series temporales: Dinámicas de crecimiento no capturadas

Trabajo Futuro:

- Análisis temporal: Rastrear evolución de comunidades y surgimiento de influencers
- Modelos híbridos: Integrar contenido (NLP en títulos/descripción) con estructura
- Causalidad: ¿Influencers generan conexiones o viceversa? Hacer análisis de causalidad
- Transfer learning: Aplicar embeddings a predicción de crecimiento futuro
- Métodos de explicabilidad: SHAP/LIME para interpretación más granular de predicciones

4.4. Reflexión Final

Este proyecto demuestra que plataformas digitales como Twitch no son simplemente colecciones de usuarios independientes, sino ecosistemas complejos con estructuras emergentes y leyes estadísticas profundas. La ciencia de redes, combinada con aprendizaje automático, proporciona herramientas poderosas para revelar estas estructuras y extraer información accionable. El hallazgo de que PageRank domina la popularidad es profundo: sugiere que en la era digital, la posición en la red social es el factor determinante de influencia, más aún que características individuales del contenido.

Referencias

Referencias

- [1] Barabási, A.-L. (2016). *Network Science*. Cambridge University Press.
Referencia canónica sobre redes complejas, distribución de grados, hubs y leyes de potencia. Proporciona base teórica para entender la estructura scale-free de Twitch.
- [2] Clauset, A., Shalizi, C. R., & Newman, M. E. (2009). Power-law distributions in empirical data. *SIAM Review*, 51(4), 661–703.
Metodología rigurosa para detectar y validar leyes de potencia. Implementamos su método Kolmogorov–Smirnov para validar que Twitch es scale-free.
- [3] Grover, A., & Leskovec, J. (2016). node2vec: Scalable feature learning for networks. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 855–864).
Trabajo seminal en embeddings de red. Node2Vec genera representaciones latentes que capturan proximidad estructural, usadas para visualización y features en modelos.
- [4] Blondel, V. D., Guillaume, J.-L., Lambiotte, R., & Lefebvre, E. (2008). Fast unfolding of communities in large networks. *Journal of Statistical Mechanics: Theory and Experiment*, 2008(10), P10008.
Algoritmo de Louvain para detección rápida de comunidades modulares. Escalable a millones de nodos, permitió detectar 23 comunidades en Twitch.
- [5] McKinney, W. (2010). Data structures for statistical computing in python. In *Proceedings of the 9th Python in Science Conference* (Vol. 445, pp. 51–56).
Pandas: librería fundamental para manipulación y análisis de datos. Usado para procesar features y atributos de usuarios.
- [6] Hagberg, A. A., Schult, D. A., & Swart, P. J. (2008). Exploring network structure, dynamics, and function using NetworkX. In *Proceedings of the 7th Python in Science Conference* (pp. 11–15).
NetworkX: librería de Python para análisis de grafos. Usada para construcción, análisis de centralidades, y detección de comunidades.
- [7] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794).
XGBoost: framework de gradient boosting. Usado en ambas tareas de predicción con excelente rendimiento.

-
- [8] Pedregosa, F., Varoquaux, G., Gramfort, A., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
Scikit-learn: librería de machine learning estándar en Python. Proporciona baselines (Logistic Regression, Random Forest) y métricas de evaluación.
- [9] McInnes, L., Healy, J., Melville, J. (2020). UMAP: Uniform manifold approximation and projection for dimension reduction. *arXiv preprint arXiv:1802.03426*.
UMAP: técnica moderna de reducción de dimensionalidad que preserva estructura local. Usada para proyectar embeddings Node2Vec a 2D manteniendo clusters cohesivos.